

# Теория и реализация языков программирования.


## Задание 2: НКА и алгоритмы поиска подстрок

Сергей Володин, 272 гр.

задано 2013.09.11


### Упражнение 0

Автомат, распознающий  $\emptyset$ :



У него нет принимающих состояний, поэтому ни одно слово не будет принято.


Автомат, распознающий  $\{\sigma\}$ :



Очевидно, автомат примет  $\sigma$ :  $(q_0, \sigma) \vdash (q_1, \varepsilon)$ , и  $q_1 \in F$ . Пусть автомат принял слово  $w$ . Поскольку начальных и принимающих состояний по одному, и между ними один переход  $\delta(q_0, \sigma) = \{q_1\}$ , получаем  $(q_0, w) \vdash (q_1, \varepsilon)$ . Отсюда  $w = \sigma$ .

### Упражнение 1

$L(\mathcal{A}) = X, L(\mathcal{B}) = Y$ . Докажем, что  $L(\mathcal{C}) = X \cdot Y$ ,  $\mathcal{C}$  — автомат из условия:



Докажем, что  $w \in X \cdot Y \Rightarrow w \in L(\mathcal{C})$ :

$w \in X \cdot Y \Rightarrow w = xy, x \in X, y \in Y$ . Тогда  $x \in L(\mathcal{A})$ , то есть,  $(q_0^A, x) \vdash^* (q_F^A, \varepsilon)$ . Аналогично  $(q_0^B, y) \vdash^* (q_F^B, \varepsilon)$ .

Пусть для некоторого автомата  $(q_1, cx) \vdash (q_2, x)$ . Это значит, что  $\delta(q_1, c) \ni q_2$ . Но отсюда  $(q_1, cxy) \vdash (q_2, xy)$ ,  $x, y$  — некоторые слова. Пусть  $(q_1, x) \vdash^* (q_2, y)$ . Это значит, что существует цепочка  $(q_1, x) \vdash \dots \vdash (q_2, y)$ . Применяя утверждение выше, получаем  $(q_1, xz) \vdash \dots \vdash (q_2, yz)$ , а отсюда  $(q_1, xz) \vdash^* (q_2, yz)$ . Очевидно, рассуждение верно и в обратную сторону: если  $(q_1, xz) \vdash^* (q_2, yz)$ , то  $(q_1, x) \vdash^* (q_2, y)$ .

Из предыдущего утверждения получаем для автомата  $\mathcal{A}$   $(q_0^A, xy) \vdash^* (q_F^A, y) \equiv (q_0^B, y) \vdash^* (q_F^B, \varepsilon)$ , то есть,  $(q_0^A, w) \vdash^* (q_F^B, \varepsilon) \Rightarrow w \in L(\mathcal{C})$ .

Докажем обратное:  $w \in L(\mathcal{C}) \Rightarrow w \in X \cdot Y$ .

Пусть  $w \in L(\mathcal{C})$ . Тогда  $(q_0^A, w) \vdash \dots \vdash (q_F^B, \varepsilon)$ . Докажем, что в этой цепочке встретилось состояние  $(q_F^A, y)$ .

В этой цепочке был переход из  $q_A \in Q^A$  в  $q_B \in Q^B$ , т.к. иначе получим, что все переходы были внутри множества состояний  $Q^A$ . Поэтому  $\exists q^A \exists \sigma \in \Sigma : \delta(q^A, \sigma) \ni q^B$ . Но изначально множество  $Q^A$  — множество состояний автомата  $\mathcal{A}$ , поэтому  $\delta(Q^A \times \Sigma) \subseteq 2^{Q^A}$ . Получаем  $q^B \in Q^A$ . По условию  $Q^A \cap Q^B = \{q_F^A\}$ , откуда получаем требуемое: в цепочке встретилось  $(q^A, \sigma y) \vdash (q_F^A, y)$ .


Таким образом,  $(q_0^A, w) \vdash^* (q_F^A, y) \vdash^* (q_F^B, \varepsilon)$ . Поскольку  $y$  — суффикс  $w$ , то  $w = xy$ . Из доказанного ранее получаем  $(q_0^A, x) \vdash^* (q_F^A, \varepsilon)$ , откуда  $x \in L(\mathcal{A}) = X$ . Аналогично  $y \in L(\mathcal{B}) = Y$ . Найдены  $x \in X$  и  $y \in Y$ :  $w = xy$ . Отсюда  $w \in X \cdot Y$ .

### Упражнение 2


### Упражнение 3

## Задача 1


Пользуясь доказанным ранее, построим автомат для  $ab$ :




Для  $ab|b$ :



Для  $(ab|b)^*$ :




Для  $a(ab|b)^*b$ :



## Задача 2


а. Докажем, что автомат  $\mathcal{A}$  распознает  $L_3$ :



1.  $w \in L_3$ . Тогда  $w[n-3] = 1 \Leftrightarrow w = x1\sigma_1\sigma_2$ .  $x \in \Sigma^* \Rightarrow$  после обработки  $x$  автомат может оказаться в  $q_0$ :  $(q_0, x1\sigma_1\sigma_2) \vdash^* (q_0, 1\sigma_1\sigma_2)$ . Далее  $(q_0, 1\sigma_1\sigma_2) \vdash (q_1, 1\sigma_1\sigma_2) \vdash (q_2, \sigma_1\sigma_2)$ .  $\sigma_1, \sigma_2 \in \Sigma \Rightarrow (q_2, \sigma_1\sigma_2) \vdash (q_3, \sigma_2) \vdash (q_4, \varepsilon)$ . Таким образом,  $(q_0, w) \vdash^* (q_4, \varepsilon) \Rightarrow w \in L(\mathcal{A})$ .
2.  $w \in L(\mathcal{A}) \Rightarrow (q_0, w) \vdash^* (q_4, \varepsilon)$ . Поскольку переход в  $q_4$  только один:  $\exists! q : \delta(q, \sigma) \ni q_4, q = q_3$ , получаем, что в цепочке конфигураций на последнем месте переход  $(q_3, \sigma) \vdash (q_4, \varepsilon)$ ,  $\sigma$  — суффикс  $w$ . Аналогично получаем  $(q_1, 1\sigma_1\sigma_2) \vdash^* (q_4, \varepsilon)$ ,  $1\sigma_1\sigma_2$  — суффикс  $w$ , откуда  $w \in L_3$ .

b. Построим ДКА  $\mathcal{B}$  по НКА  $\mathcal{A}$ :


$Q$	$q$	$0(q)$	$0(Q)$	$1(q)$	$1(Q)$
$Q_0$	$q_0, q_1$	$q_0, q_1$	$Q_0$	$q_0, q_1, q_2$	$Q_1$
$Q_1$	$q_0, q_1, q_2$	$q_0, q_1, q_3$	$Q_2$	$q_0, q_1, q_2, q_3$	$Q_3$
$Q_2$	$q_0, q_1, q_3$	$q_0, q_1, q_4$	$Q_4$	$q_0, q_1, q_2, q_4$	$Q_5$
$Q_3$	$q_0, q_1, q_2, q_3$	$q_0, q_1, q_3, q_4$	$Q_6$	$q_0, q_1, q_2, q_3, q_4$	$Q_7$
$Q_4$	$q_0, q_1, q_4$	$q_0, q_1$	$Q_0$	$q_0, q_1, q_2$	$Q_1$
$Q_5$	$q_0, q_1, q_2, q_4$	$q_0, q_1, q_3$	$Q_2$	$q_0, q_1, q_2, q_3$	$Q_3$
$Q_6$	$q_0, q_1, q_3, q_4$	$q_0, q_1, q_4$	$Q_4$	$q_0, q_1, q_2, q_4$	$Q_5$
$Q_7$	$q_0, q_1, q_2, q_3, q_4$	$q_0, q_1, q_3, q_4$	$Q_6$	$q_0, q_1, q_2, q_3, q_4$	$Q_7$



Заметим, что в построенном автомате  $8 = 2^3$  состояний.

### Задача 3

В исходном автомате  $\mathcal{A} : L(\mathcal{A}) = L_n$  будет  $n + 2$  состояний (при  $n = 3$  состояний 5, при увеличении  $n$  на 1 количество состояний также будет увеличиваться на 1, так как в конце слова должен стоять еще один произвольный символ).



(Идея из Хопкрофта, 2.3.6: плохой случай для конструкции подмножеств)

Предположим, что в ДКА  $\mathcal{B} : L(\mathcal{B}) = L_n$  меньше  $2^n$  состояний. Тогда по принципу Дирихле (т.к. состояний меньше, чем строк из  $n$  символов)  $\exists a = a_1 \dots a_n \exists b = b_1 \dots b_n : a \neq b$  и  $(Q_0, a) \vdash^* (Q, x), (Q_0, b) \vdash^* (Q, y)$ , то есть, после обработки  $a$  или  $b$  автомат переходит в состояние  $Q$ . Поскольку  $a \neq b, \exists i : a_i \neq b_i$ .

1.  $i = 1$ . Это значит, что отличаются первые символы строк. Без ограничения общности,  $a_1 = 1, b_1 = 0$ . Но тогда  $a \in L(\mathcal{B})$ , так как  $n$ -й символ с конца строки  $a$  равен 1. Поэтому  $Q \in F_{\mathcal{B}}$ . Аналогично, так как  $b_1 = 0, b \notin L(\mathcal{B}) \Rightarrow Q \notin F_{\mathcal{B}}$  — противоречие.

2.  $i > 1$ . Тогда, без ограничения общности,  $a_i = 1, b_i = 0$ . Дополним строки  $a$  и  $b$  чем-либо (например, нулями) справа так, чтобы  $i$ -й символ стал  $n$ -м:  $a' = a_1 \dots a_i \dots a_n \underbrace{0 \dots 0}_{i-1}, b' \text{ — аналогично}$ . Тогда  $a' \in L(\mathcal{B}), b' \notin L(\mathcal{B})$ .

Но  $(Q_0, a') \vdash^* (Q, 0 \dots 0) \vdash^* (P, \varepsilon)$ ,

$(Q_0, b') \vdash^* (Q, 0 \dots 0) \vdash^* (P, \varepsilon)$ , откуда состояние  $P$  должно быть как принимающим, так и не принимающим — противоречие.

Получаем, что в НКА  $\mathcal{A}$   $O(n)$  состояний, а в любом ДКА  $\mathcal{B} : L(\mathcal{B}) = L_n$   $2^n$  состояний. В том числе  $2^n$  состояний будет у того ДКА, который построен по  $\mathcal{A}$  при помощи алгоритма ■

Задача 4

Построим ДКА  $\mathcal{B}$  по НКА  $\mathcal{A}$ :


$Q$	$q$	$a$	$b$
$Q_0$	$q_0$	$Q_1$	$Q_0$
$Q_1$	$q_0, q_1$	$Q_1$	$Q_2$
$Q_2$	$q_0, q_2$	$Q_3$	$Q_0$
$Q_3$	$q_0, q_1, q_3$	$Q_1$	$Q_4$
$Q_4$	$q_0, q_2, q_4$	$Q_5$	$Q_0$
$Q_5$	$q_0, q_1, q_3, q_5$	$Q_1$	$Q_6$
$Q_6$	$q_0, q_2, q_4, q_6$	$Q_7$	$Q_8$
$Q_7$	$q_0, q_1, q_3, q_5, q_6$	$Q_9$	$Q_6$
$Q_8$	$q_0, q_6$	$Q_9$	$Q_8$
$Q_9$	$q_0, q_1, q_6$	$Q_9$	$Q_{10}$
$Q_{10}$	$q_0, q_2, q_6$	$Q_{11}$	$Q_8$
$Q_{11}$	$q_0, q_1, q_3, q_6$	$Q_9$	$Q_6$

Начальное состояние —  $Q_0$ , принимающие —  $\{Q_6, Q_7, Q_8, Q_9, Q_{10}, Q_{11}\}$ .

Задача 5

Задача 6

Пусть  $n = |w|$ . Тогда определим  $Q = \{q_0, q_1, \dots, q_n\}$ ,  $F = \{q_n\}$ .



Определим  $l'(i) = |l(w_1 \dots w_i)|$ .  
Определим функцию  $f(i, \sigma)$  — длина максимального префикса слова  $w_1 \dots w_i$ , который совпадает с его суффиксом, причем после префикса стоит символ  $\sigma$ . Построение  $f$  аналогично построению префикс-функции: пусть построены значения при  $i < m$ . Построим для  $m$ : рассмотрим следующий символ  $w_{m+1}$ . Если  $w_{m+1} = \sigma$ , то  $f(m, \sigma) = m$ , иначе найдем максимальный несобственный префикс слова  $w_1 \dots w_m$ , являющийся его суффиксом, причем после префикса следует  $\sigma$ . Длина этого суффикса —  $f(l'(m), \sigma)$  — уже найдена (т.к.  $l'(m) < m$ ). Определим  $f(0, \sigma) = -1$ , если  $w_1 \neq \sigma$ .

Определим функцию переходов  $\delta$  через  $f$ :  $\delta(q_i, \sigma) = \begin{cases} \{q_{i+1}\} & \text{если } w_{i+1} = \sigma \\ \{q_{f(i, \sigma)+1}\} & \text{иначе} \end{cases}$ .

Свойство: номер состояния — длина максимального префикса слова  $w$ , который входит во входное слово, причем вхождение заканчивается на рассматриваемом автомате символе.

Первый случай, очевидно, корректный (сохраняет свойство выше): если совпало  $i$  символов, и следующий символ  $\sigma$  совпадает с  $w_{i+1}$ , то всего совпадает  $i + 1$  символ (и не больше)  $\Rightarrow$  переход в  $q_{i+1}$ .

Во втором случае следующий входной символ отличается от  $w_{i+1}$ . Поскольку текущий символ —  $\sigma$ , необходимо рассматривать префиксы, заканчивающиеся на этот символ. Максимальный префикс  $p_2$ , требуемый свойством в текущей конфигурации, очевидно, по длине не больше  $|p_1| + 1$ , где  $p_1$  — требуемый свойством префикс на предыдущей конфигурации: иначе префикс  $p_1$  не был бы максимальным (максимальным был бы  $p_2$  без последнего символа  $\sigma$ ).

Также  $|p_2| \neq |p_1| + 1$ , так как иначе  $p_2$  получался из  $p_1$  приписыванием  $\sigma$ , что невозможно, так как  $\sigma \neq w_{i+1}$ . Итак,  $p_2 < |p_1| + 1$ . Рассмотрим  $p'_2 = p_2$  без последнего символа  $\sigma$ . Тогда  $|p'_2| < |p_1|$ .

Заметим, что  $p'_2$  — суффикс  $p_1$ , так как они оба подстроки входного слова, причем вхождение заканчивается в одной и той же позиции. Также  $p'_2$  — префикс  $p_1$ , так как они — префиксы  $w$ . Таким образом,  $p'_2$  — суффикс и префикс  $p_1 = w_1 \dots w_i$ . Таким образом, необходимо найти в строке  $w_1 \dots w_i$  префикс, который является суффиксом. Ранее требовалось, чтобы после префикса следовал символ  $\sigma$ . Из свойства он должен быть максимальным по длине. Таким образом, необходимо взять префикс длины  $f(i, \sigma)$ , и переход должен быть в состояние с номером на 1 большее, так как будет обработан и символ  $\sigma$  (этим доказано сохранение Свойства во втором случае).

Пусть автомат находится на позиции, в которой заканчивается вхождение  $w$ . Тогда, по свойству, он будет находиться в последнем, принимающем состоянии  $\Rightarrow$  слово будет принято.

Пусть входное слово не содержит  $w$ . Тогда длина префикса  $w$ , который входит во входное слово не достигнет  $|w| \Rightarrow$  по свойству автомат не перейдет в принимающее состояние.

# Задача 7

## Построение префикс-функции

```
Looking at [1], a: lastP=<> Found P=<>
Looking at [2], b: lastP=<> lastP=<> break Found P=<>
Looking at [3], b: lastP=<> lastP=<> break Found P=<>
Looking at [4], a: lastP=<> Found P=<a>
Looking at [5], #: lastP=<a> lastP=<> break Found P=<>
Looking at [6], a: lastP=<> Found P=<a>
Looking at [7], b: lastP=<a> Found P=<ab>
Looking at [8], b: lastP=<ab> Found P=<abb>
Looking at [9], b: lastP=<abb> lastP=<> break Found P=<>
Looking at [10], a: lastP=<> Found P=<a>
Looking at [11], b: lastP=<a> Found P=<ab>
Looking at [12], a: lastP=<ab> lastP=<> break Found P=<a>
Looking at [13], b: lastP=<a> Found P=<ab>
Looking at [14], b: lastP=<ab> Found P=<abb>
Looking at [15], a: lastP=<abb> Found P=<abba>
Looking at [16], b: lastP=<abba> lastP=<a> Found P=<ab>
```

## Префикс-функция

Номер	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Символ	<i>a</i>	<i>b</i>	<i>b</i>	<i>a</i>	<i>#</i>	<i>a</i>	<i>b</i>	<i>b</i>	<i>b</i>	<i>a</i>	<i>b</i>	<i>a</i>	<i>b</i>	<i>b</i>	<i>a</i>	<i>b</i>
Функция	0	0	0	1	0	1	2	3	0	1	2	1	2	3	4	2

## Результат

Found, starting from 12

<https://bitbucket.org/etoestja/inf/raw/HEAD/mipt/s3/TIPL/2/KMP.c> — исходный код. Запускать:

```
$ cc KMP.c -o KMP
$ echo "abba abbbababbab" | ./KMP
```